Как языковая модель помогает улучшать рекомендации товаров

25 октября 2026 года

Автоматический поиск признаков и подбор товаров для рекомендации.

Может ли языковая модель находить способы улучшить рекомендации товаров?

Для первого сравнения использован REES46, журнал действий покупателей интернет-магазина. Здесь набор товаров для возможной рекомендации и настройки модели одинаковы для всех вариантов, поэтому можно проверить пользу добавленных признаков. Второй эксперимент проведён в задаче Kaggle OTTO, где по первым действиям покупателя нужно предсказать его дальнейший интерес к товарам. Он показывает, может ли агент на основе языковой модели последовательно развивать уже созданную систему. В обоих экспериментах оценки качества рекомендаций выросли.

1 Что делает агент

Рекомендательная система сначала подбирает кандидатов, то есть товары для возможной рекомендации. Затем модель ранжирования, или ранкер, упорядочивает их по признакам. Такими признаками могут быть популярность товара и интерес пользователя к его категории.

Агент на основе языковой модели (LLM) получает описание данных и пишет SQL-запросы для расчёта новых признаков. Предложения проверяются, признаки рассчитываются, а модель ранжирования с ними переобучается. Оценки качества и ошибки предыдущих попыток помогают агенту выбрать следующую идею. Постановку, модель ранжирования, ограничения и правила запуска задаём мы.

2 Данные и исходная система REES46

REES46 содержит журнал просмотров товаров, добавлений в корзину и покупок одного многокатегорийного магазина. Доступны товар, категория, бренд, цена и сессия; названий товаров и профилей пользователей нет.

По истории действий пользователя предсказываем, какие новые для него товары он добавит в корзину или купит в следующие сутки. Новыми считаем товары, с которыми пользователь ещё не взаимодействовал в доступной истории. В данных не указано, откуда пользователь перешёл к товару: из рекомендаций, поиска или другого раздела магазина. Поэтому оцениваем предсказание последующих действий, а не влияние рекомендательной ленты на покупки.

Для каждого дня используем только события до его начала; целевые действия берём за следующие 24 часа. Целевым событием считаем первое добавление товара в корзину либо покупку, если в данных нет предшествующего добавления в корзину.

Один запрос соответствует одному пользователю и одному дню оценки. В оценку входят запросы пользователей, активных за предыдущие 48 часов и совершивших хотя бы одно целевое действие в следующие сутки. Метрика NDCG@20 оценивает порядок первых двадцати рекомендаций. В её расчёт входят все целевые товары, включая не попавшие в кандидаты.

Исходную систему далее называем базой. Кандидатов в ней подбирают по популярности, предпочтениям категорий и брендов, совместным просмотрам и переходам от просмотра к корзине или покупке. Их ранжирует градиентный бустинг CatBoost с функцией потерь Logloss. Он использует активность пользователя, популярность и конверсию товара, интерес к его категории и бренду, соответствие цены привычкам пользователя и связи с просмотренными товарами. Настройки ранкера и способы выбора отрицательных примеров проверяли на валидации, то есть на данных для выбора вариантов. Затем условия обучения зафиксировали.

Часть признаков базы основана на идеях, полученных при более раннем автоматическом поиске признаков.

3 Какие признаки предложил и отобрал агент

Поиск проводили на данных 2019 года. Валидацию разделили на две части: на первой выбирали варианты, на второй, подтверждающей, проверяли, сохраняется ли улучшение.[1]

За шесть раундов LLM-агент предложил 30 SQL-преобразований. Он видел схему данных, текущие признаки, оценки и ошибки прежних попыток, но не строки данных и целевые ответы. Признаки рассчитывали только по прошлым событиям. Для проверки каждого предложения модель переобучали с ранее принятыми и новыми признаками. В каждом раунде принимали лучшее предложение, если прирост NDCG@20 превышал порог отбора 0.0005, а доверительный интервал прироста лежал выше нуля в двух запусках обучения. Так отобрали одно предложение с двумя признаками близости кандидата к товарам, к которым пользователь возвращался в нескольких сессиях.

Для сравнения использовали автоматическую генерацию признаков по заданным правилам, без языковой модели. Этот вариант обозначаем DFS (Deep Feature Synthesis, автоматический синтез признаков). В нашей реализации программа перебирает заданные временные окна и типы событий и рассчитывает статистики пользователя, товара, категории и бренда. Например, программа рассчитывает признак на основе числа просмотров товара за последние семь дней. Полученные признаки отбирали по важности на обучающих данных.

4 Что дало добавление всех признаков

Пошаговый отбор оставил только одно предложение. После первоначального теста 2019 года решили проверить, полезен ли полный набор рассчитанных признаков агента и DFS, включая не прошедшие отбор. Сначала гипотезу проверили на валидации 2019 года, затем на новом тесте в феврале 2020 года. Модели переобучили на предшествующей истории этого периода. Для всех вариантов сохранили одинаковые разбиение, кандидатов, доступную историю и настройки обучения.

Вариант на тесте 2020	**NDCG@20**	**Изменение**
База	0.1462	база
База + отобранное предложение агента	0.1470	+0.0008
База + отобранные признаки DFS	0.1459	−0.0003
База + весь набор агента и DFS	**0.1492**	**+0.0030**

Среднее двух запусков обучения. Изменение относительно базы рассчитано до округления.[2]

[1] Оценки подтверждающей части были видны в ранних прогонах. Отобранное предложение включили в тест 2019 года, хотя на этой части улучшение не подтвердилось. Подробности приведены в журнале исследования.

[2] 27–28 февраля исключены по заранее заданному правилу аномального падения числа событий. Даты и условия сравнения приведены в протоколе теста.

Полный набор увеличил NDCG@20 примерно на 2% относительно базы. Заранее заданный критерий улучшения выполнен в обоих запусках обучения.[3] В этом эксперименте полный набор оказался полезнее пошагового отбора: отобранное предложение дало небольшой прирост, а отобранные признаки DFS не улучшили базу.

Полные результаты всех вариантов и дополнительные проверки приведены в инструкции воспроизведения.

5 Сохраняется ли выигрыш без DFS

Совместный набор объединяет два способа генерации. Его результат сам по себе не показывает, нужны ли признаки DFS в дополнение к предложениям агента. Последующие проверки на валидации обоих периодов показали, что полный набор агента улучшал базу и без DFS. Интервалы разницы между совместным набором и набором только агента включали ноль.

Чтобы проверить, связано ли улучшение с содержанием новых признаков, мы случайно переставили их целыми наборами между парами «пользователь и товар» внутри каждого дня. Базовые признаки и правильные ответы оставили прежними, затем заново обучили модель. Выигрыш на валидации исчез. Это ожидаемый результат: дополнительные признаки потеряли связь с теми пользователями и товарами, которых описывали. Проверка поддерживает вывод, что полезна информация в признаках, а не просто увеличение их числа.

Затем на уже просмотренном тесте отдельно обучили и проверили вариант «база + весь набор агента без DFS» с теми же настройками и двумя запусками обучения. Средний NDCG@20 составил **0.1491** против 0.1462 у базы, прирост около **2.0%**. В обоих запусках 95%-е интервалы прироста с группировкой по пользователям выше нуля. Интервалы разницы между совместным набором и набором только агента включают ноль в обоих запусках; это не доказывает равенства вариантов. Этот дополнительный разбор не является независимой итоговой проверкой.

6 Может ли агент последовательно улучшать систему

На REES46 состав кандидатов оставался фиксированным. В опытах на OTTO агенту разрешили менять и подбор товаров. В задаче Kaggle OTTO по началу сессии нужно предсказать товар следующего клика и товары последующих добавлений в корзину и заказов. Итоговая метрика объединяет доли целевых товаров, попавших в первые двадцать рекомендаций для каждого из этих действий. **Private score** показывает качество на части теста Kaggle, правильные ответы для которой наша система не использовала. После каждой отправки предсказаний Kaggle показывал значение этой метрики.

Агент создаёт таблицы связей между товарами и использует их для подбора кандидатов и расчёта признаков. Например, предлагает товары, которые добавляли в корзину или заказывали вместе, либо товары, к которым переходили после похожих просмотров. Среди предложенных идей были переходы с учётом типа события, похожие исторические сессии и оценка длительности просмотра по промежуткам между событиями.

Первый запуск агента улучшил простую систему на основе истории сессии и популярности. Затем мы изменили обучение ранкера, сохранив предложенные агентом источники кандидатов и признаки. Полученное решение назвали OTTO-2 и использовали как исходное для следующих трёх итераций поиска.

В первых двух итерациях агент добавлял источники кандидатов и признаки, в третьей только признаки. Настройки обучения ранкера во всех трёх итерациях оставались прежними.

[3] До теста потребовали прирост не меньше 0.0015 и положительную нижнюю границу 95%-го интервала прироста в каждом запуске. Интервалы рассчитаны повторными выборками запросов; они не оценивают разброс новых запусков агента.



Изменение private score после трёх итераций агента.

Каждая итерация улучшала результат на локальной валидации и private. Суммарный относительный прирост private score составил около **2.7%** к OTTO-2. Итоговый private score 0.59628 соответствовал бы примерно 22-му месту и серебряной медали в финальной таблице соревнования. Первые два шага одновременно меняли кандидатов и признаки, поэтому их вклады не разделены. Польза каждого отдельного признака не измерялась.

7 Выводы

В обоих экспериментах агент помог улучшить готовую рекомендательную систему. На REES46 добавление признаков повысило качество на новом периоде данных. На OTTO три последовательные итерации улучшили решение, которое уже использовало предложенные агентом признаки и источники кандидатов. Сравнение с ручным поиском при одинаковом вычислительном бюджете не проводилось.

Проверка REES46 ограничена одним магазином. Повторяемость серии улучшений OTTO при новом запуске поиска не проверяли.

В OTTO оценки Kaggle использовались для дальнейшего поиска. Рост private score показывает последовательное развитие решения, а не независимую проверку заранее выбранного варианта.

8 Материалы и воспроизведение

Репозиторий проекта; инструкции для REES46 и OTTO; результаты теста 2020 года и оценки предсказаний OTTO.