LLM-агент для признаков и кандидатов в рекомендательной системе

Проверка на REES46 и развитие решения OTTO

Главный результат. На REES46 совместный набор признаков агента и автоматических агрегатов улучшил базовую модель на данных более позднего периода примерно на **2% по NDCG@20**. На OTTO агент менял также подбор товаров и за **три последовательные итерации** улучшил собственное решение.

1. Что мы поручили агенту

Система сначала подбирает **кандидатов** (товары для рекомендации), затем модель ранжирования (**ранкер**) упорядочивает их по признакам: например, популярности товара и интересу пользователя к его категории.

Агент на основе языковой модели (LLM) получает описание данных и пишет SQL-запросы для расчёта новых признаков.

Идея и SQL ⟶ **Проверка и расчёт** ⟶ **Оценка качества**

Результаты предыдущих предложений помогают выбрать следующую идею.

На REES46 агент дополняет заданный набор признаков. На OTTO он может создавать ещё и источники кандидатов. Постановку, модель, ограничения и правила запуска задаём мы.

2. REES46: добавочные признаки к готовой базе

REES46 содержит журнал просмотров, корзин и покупок одного многокатегорийного магазина. Доступны товар, категория, бренд, цена и сессия; названий товаров и профилей пользователей нет.

Задача. В начале дня рекомендуем товары, с которыми пользователь не взаимодействовал в доступной истории. Целью считаем первое добавление такого товара в корзину или его покупку в следующие 24 часа. Покупки включены в цель, поскольку запись о предшествующем добавлении в корзину есть не всегда.

Запросом называем рекомендации одному пользователю в начале дня. В оценку входят запросы пользователей, активных за предыдущие 48 часов и совершивших хотя бы одно целевое действие в следующие сутки. Метрика NDCG@20 оценивает порядок первых двадцати рекомендаций. В её расчёт входят все целевые товары, включая не попавшие в кандидаты.

База. Кандидатов подбирают по популярности, предпочтениям категорий и брендов, совместным просмотрам и переходам от просмотра к корзине или покупке. Их ранжирует градиентный бустинг CatBoost с функцией потерь Logloss. Он использует активность пользователя, популярность и конверсию товара, интерес к его категории и бренду, соответствие цены привычкам пользователя и связи с просмотренными товарами. На валидации проверяли настройки ранкера и способы выбора отрицательных примеров, затем условия обучения зафиксировали.

База подготовлена с помощью Claude Code и включает идеи ранней генерации признаков. Эксперимент проверяет, улучшают ли новые признаки эту систему, а не сравнивает способности LLM и человека.

REES46: как проверяли и что получили

Поиск проводили на данных 2019 года. Валидацию разделили на две части: на первой выбирали варианты, на второй, подтверждающей, проверяли, сохраняется ли улучшение.

Поиск и отбор. За шесть раундов LLM-агент предложил 30 SQL-преобразований. Он видел схему, текущие признаки, оценки и ошибки прежних попыток, но не строки данных и целевые ответы. Признаки рассчитывали только по прошлым событиям. Для проверки каждого предложения модель переобучали с ранее принятыми и новыми признаками. В каждом раунде принимали лучшее предложение, если прирост NDCG@20 превышал порог отбора 0.0005, а доверительный интервал лежал выше нуля в двух запусках обучения. Так отобрали одно предложение с двумя признаками: близость кандидата к товарам, к которым пользователь возвращался в нескольких сессиях. Число раундов задавал человек.

Для контроля использовали фиксированную сетку агрегатов (в коде **DFS**). Она без LLM перебирает заданные окна и типы событий, рассчитывая статистики пользователя, товара, категории и бренда. Её признаки отбирали по важности на обучающих данных.

Проверка на новом периоде. После первоначального теста на данных 2019 года возникла гипотеза: добавить все признаки агента и DFS без отбора. Сначала её проверили на валидации 2019, затем на новом тесте в феврале 2020. Перед тестом модели переобучили на предшествующей истории 2020 года, сохранив настройки и правила расчёта признаков из 2019.

Для вариантов в таблице совпадали разбиение, кандидаты, доступная история и настройки модели. Полный набор агента и DFS расширяет базу с 80 до 274 признаков. В таблице приведено среднее по двум запускам обучения с разными начальными состояниями генератора случайных чисел (seed).

Критерий успеха. До открытия теста для полного набора потребовали абсолютный прирост NDCG@20 не меньше 0.0015 и положительную нижнюю границу 95%-го доверительного интервала в обоих запусках. Интервалы получены повторными выборками запросов и не отражают разброс новых запусков самого агента.

Тест: 14–29 февраля 2020, около 98 тыс. запросов; 27–28 февраля исключены по заранее заданному правилу аномального падения числа событий. Обучение перед тестом: 15 января – 13 февраля.

Вариант на тесте 2020	NDCG@20	Изменение
База	0.1462	база
База + отобранное предложение агента	0.1470	+0.0008
База + отобранные признаки DFS	0.1459	−0.0003
База + весь набор агента и DFS	**0.1492**	**+0.0030**
Автоматические признаки вместо ручных	0.1451	−0.0011

Изменение относительно базы. Разности посчитаны до округления. При замене ручных признаков сохранены позиции товаров в списках кандидатов.

Полный набор прошёл заранее заданную проверку.

Прирост и 95%-й интервал по запускам: $+0.0031$ $[+0.0025; +0.0036]$ и $+0.0029$ $[+0.0023; +0.0035]$.

Что не сработало. Эффект отобранного предложения ослаб на подтверждающей части. На новом тесте выигрыш остался ниже практического порога 0.001 для отдельного предложения. Полная замена ручных признаков немного уступила базе; отдельно этот вариант не настраивали.

В последующих проверках прироста полного набора относительно базы интервалы остались выше нуля при группировке запросов отдельно по пользователям и дням; выигрыш

сохранялся и при исключении любого одного дня. Дневная оценка ограничена 14 днями; совместные зависимости по пользователям и дням не учитывались. В обоих запусках выросла и полнота рекомендаций (Recall@20). На запросах с покупками выросли NDCG@20 и Recall@20 только купленных товаров. Интервалы этих приростов при группировке по пользователям также выше нуля.

Последующие проверки на валидации. Перемешивание автоматических признаков между строками внутри дня сохраняло их число и распределения, но убирало выигрыш. Полный набор агента улучшал базу без DFS; интервалы добавочного эффекта DFS на валидации обоих периодов включали ноль.

Дополнительный разбор теста. Отдельно обучили вариант «база + весь набор агента без DFS» с теми же настройками и двумя seed. Средний NDCG@20 составил **0.1491** против 0.1462 у базы, прирост около **2.0%**. В обоих запусках 95%-е интервалы прироста с группировкой по пользователям выше нуля. Оба интервала добавочного эффекта DFS включают ноль; это не доказывает равенства вариантов. Такой разбор уже просмотренного теста не является независимой итоговой проверкой.

3. OTTO: три улучшения агентной системы

В задаче Kaggle OTTO по началу сессии нужно предсказать товар следующего клика и товары последующих добавлений в корзину и заказов. Итоговая метрика объединяет полноту первых двадцати рекомендаций для этих действий. **Private score** показывает качество на части теста Kaggle, метки которой наша система не использовала. После каждой отправки предсказаний Kaggle показывал значение этой метрики.

Как работает агент. Он создаёт таблицы связей между товарами для подбора кандидатов и расчёта признаков. Например, предлагает товары, которые добавляли в корзину или заказывали вместе, либо товары, к которым переходили после похожих просмотров.

Первый запуск агента усилил простую систему на основе истории сессии и популярности. Затем мы изменили обучение ранкера, сохранив предложенные агентом источники кандидатов и признаки; так получили OTTO-2. Следующие три итерации запускал человек. **Способ обучения ранкера оставался прежним**, а агент развивал набор кандидатов и признаков.

Итерация	Что изменилось
Первая	Новый запуск агента с расширенными лимитами поиска. Добавлены источники кандидатов и признаки.
Вторая	Агент дополнил предыдущий набор новыми источниками кандидатов и признаками.
Третья	Агент добавил только признаки. Кандидаты остались прежними.



Ось показана не от нуля.

Результат. Три итерации дали суммарно около **2.7%** к private относительно OTTO-2. Каждый шаг улучшал оценку на локальной валидации и private.

Первые два шага меняли одновременно кандидатов и признаки, поэтому их вклады не разделены. В числе предложенных идей были переходы с учётом типа события, похожие исторические сессии и оценка длительности просмотра по промежуткам между событиями. Польза каждого отдельного признака не измерялась.

4. Границы результатов и выводы

В этих экспериментах автоматическая генерация помогла расширить готовую систему. На REES46 полная замена ручных признаков уступила базе. Повторяемость улучшений при независимых повторах поиска от одной и той же базы не проверена ни на REES46, ни на OTTO.

REES46. Эффект проверен в одном магазине и на одном новом тестовом периоде. Устойчивость результата на других наборах данных не установлена.

- **Выбор по валидации.** Подтверждающая часть не была полностью изолирована: её оценки были видны в ранних прогонах. Правила принятия настроек базы и предложений агента различались; выбранное предложение вошло в тест 2019, хотя на подтверждающей части выигрыш не подтвердился. Последнее уточнение плана 2020 внесено после просмотра валидации, без изменения вариантов и порогов теста.
- **Настройка базы.** Настройки проверяли ограниченным набором вариантов; полного совместного поиска и сравнения при равных вычислительных бюджетах не проводили. Порог для отдельного предложения основан на разбросе между запусками обучения и не является универсальной границей полезности.
- **Доступность истории.** Сравнивали признаки по полному журналу и по истории до момента прогноза. Найденную ошибку доступности кода категории исправили до обучения моделей 2020. Возможность обойти ограничения доступа к данным устранили до запуска агента. Эти проверки уменьшают риск утечек, но не доказывают отсутствие всех возможных ошибок.

OTTO. Оценки использовались в ходе поиска, поэтому результат не равнозначен одноразовой итоговой проверке.

- **Повторное использование оценок.** Локальную валидацию многократно использовали при выборе вариантов. На Kaggle отправили девять файлов с предсказаниями; после достижения намеченной private-оценки продолжили ещё две итерации. Критерий пригодности простой базы также изменили после просмотра локальных оценок.
- **Доступность информации.** В выбранном режиме Kaggle допустимо использовать события других сессий после момента прогноза. Такой эксперимент не проверяет строгую постановку «только прошлое» из задания.
- **Контроль и новизна.** Превосходство над сильной ручной системой при одинаковых кандидатах не проверено. LLM могла воспроизводить известные решения соревнования; новизну предложений мы не установили.

Затраты. Суммарное время вычислительных этапов агента на REES46 составило около пяти часов, из них около 6% заняла работа LLM. Основное время ушло на переобучение моделей для проверки идей. В повторе 2020 чтение готовых признаков, обучение и оценка в двух запусках суммарно заняли около 21 минуты для базы и 33 минут для совместного набора агента и DFS. Это один замер без учёта расчёта признаков. В OTTO проверку утечек пришлось разбить на части: для расчёта на всей выборке не хватало памяти.

Код и воспроизведение. Репозиторий проекта; инструкции для REES46 и OTTO; числа теста 2020 и оценки предсказаний OTTO. Сырые данные, тяжёлые артефакты и расширенная проверка разброса случайных запусков находятся вне Git.

Участие ИИ. Автор выбирал направления и разрешал запуски; Claude Code проектировал значительную часть системы и написал код. Генерацию SQL исследовали как отдельный компонент. Ревью другими экземплярами LLM не исключает общих ошибок модели.