LLM-агент для признаков и кандидатов в рекомендательной системе

Проверка на REES46 и развитие решения OTTO

Главный результат. На REES46 совместный набор признаков агента и автоматических агрегатов улучшил подготовленную модель примерно на **2% по NDCG@20**. На OTTO агент получил возможность менять также подбор товаров и за **три последовательные итерации** улучшил собственное решение. Первый эксперимент проверяет добавочное качество на новом временном тесте; второй показывает развитие работающей системы в ходе поиска.

1. Что мы поручили агенту

Система сначала подбирает товары — **кандидатов**. Модель ранжирования, или **ранкер**, упорядочивает их по ожидаемой релевантности. Она использует признаки: например, популярность товара или интерес пользователя к его категории.

Мы проверяем, может ли языковая модель (LLM) предлагать полезные способы расчёта признаков. Агент получает описание данных и пишет SQL-запросы. Конвейер проверяет их, рассчитывает признаки и измеряет качество модели.

Идея и SQL ⟶ **Проверка и расчёт** ⟶ **Оценка качества**

Результаты предыдущих предложений помогают выбрать следующую идею.

На REES46 агент добавляет признаки к фиксированной базе. На OTTO он может создавать ещё и источники кандидатов. Постановку, модель, ограничения и правила запуска задаём мы; агент ищет решения внутри этих рамок.

2. REES46: добавочные признаки к готовой базе

Задача. В начале дня рекомендуем товары, с которыми пользователь раньше не взаимодействовал. Цель — первое добавление такого товара в корзину или его покупка в следующие 24 часа. Покупки включены в цель, поскольку запись о предшествующем добавлении в корзину есть не всегда.

Оцениваем пользователей, активных за предыдущие 48 часов и имеющих хотя бы одно целевое действие в будущем окне. Метрика NDCG@20 оценивает порядок первых двадцати рекомендаций. В её расчёт входят все целевые товары, включая не попавшие в кандидаты.

База. Модель CatBoost с функцией потерь Logloss использует подготовленные признаки. Источники кандидатов: популярные товары, предпочтения по категориям и брендам, совместные просмотры и переходы от просмотра к покупке.

База подготовлена с помощью Claude Code и включает идеи ранней генерации признаков. Эксперимент оценивает добавочную пользу признаков для этой системы, а не сравнивает способности LLM и человека.

REES46: как проверяли и что получили

Два способа генерации. LLM-агент предложил 30 SQL-преобразований. Каждое проверяли переобучением модели; одно предложение с двумя признаками прошло отбор. Оно оценивает близость кандидата к товарам, которые пользователь просматривал в нескольких сессиях. Агент видел схему данных и оценки прежних попыток, но не строки данных или целевые ответы. SQL выполнялся в песочнице только по событиям до момента рекомендации.

Контрольный метод **DFS** строит агрегаты за разные временные окна по заданным правилам, без LLM. Мы сравнили отобранные признаки каждого метода, весь автоматически созданный набор и вариант замены ручных признаков автоматическими.

Выбор и итоговая проверка. На данных 2019 года одну часть валидации использовали для выбора, другую — для подтверждения. После теста 2019 возникла гипотеза: добавить все признаки агента и DFS без отбора. Её впервые проверили на новом тесте в феврале 2020. Модели переобучили на истории этого периода, сохранив настройки и правила расчёта признаков из 2019.

Для всех вариантов совпадали разбиение, кандидаты, доступная история и настройки модели. База: 80 признаков, глубина 8 и 500 деревьев. Полный набор добавляет 66 признаков агента и 128 DFS. Результаты усреднены по двум запускам с разными случайными зернами.

Вариант на тесте 2020	NDCG@20	Изменение
База	0.1462	—
База + отобранное предложение агента	0.1470	+0.0008
База + отобранные признаки DFS	0.1459	−0.0003
База + весь набор агента и DFS	**0.1492**	**+0.0030**
Автоматические признаки вместо ручных	0.1451	−0.0011

Изменение относительно базы. Разности посчитаны до округления. При замене ручных признаков сохранены ранги товаров в источниках кандидатов.

Полный набор прошёл заранее заданную проверку. До открытия теста мы потребовали прирост не меньше 0.0015 и положительную нижнюю границу 95%-го доверительного интервала в обоих запусках. Оба условия выполнены. Интервалы оценивают неопределённость прироста повторными выборками запросов; разброс новых запусков самого агента они не отражают.

Прирост и 95%-й интервал по запускам: $+0.0031$ $[+0.0025; +0.0036]$ и $+0.0029$ $[+0.0023; +0.0035]$. Тест: 14–29 февраля 2020, около 98 тыс. запросов; 27–28 февраля исключены из-за повреждённого журнала. Обучение перед тестом: 15 января – 13 февраля.

Что не сработало. Выбранное предложение выглядело полезным при отборе, но на подтверждающей части эффект ослаб. На новом тесте выигрыш остался ниже принятого практического порога 0.001. DFS не улучшил базу. Полная замена ручных признаков немного уступила ей; отдельно этот вариант не настраивали.

Что показало перемешивание признаков. В последующей проверке на валидации перемешали автоматические признаки между строками внутри дня. Их число и распределения сохранились, а выигрыш исчез. Это поддерживает объяснение через содержание признаков. Однако вклад LLM отдельно от DFS на новом тесте не измерен, а преимущество добавления всего набора над пошаговым отбором прямо не проверялось.

3. OTTO: три улучшения агентной системы

На Kaggle OTTO по началу сессии нужно предсказать товары для следующих кликов, добавлений в корзину и заказов. Итоговая метрика объединяет полноту первых двадцати рекомендаций для этих действий. **Private score** — оценка Kaggle на скрытой части теста. В нашем исследовании она была видна после отправки каждой посылки.

Агент строит и кандидатов, и признаки. Он создаёт таблицы связей между товарами, затем использует их для подбора кандидатов и расчёта признаков. Например, предлагает товары, которые добавляли в корзину или заказывали вместе, либо товары, к которым переходили после похожих просмотров. Более поздние раунды могут использовать результаты предыдущих.

Первый запуск агента усилил простую систему на основе истории сессии и популярности. Затем мы изменили обучение ранкера, сохранив набор агента; этот вариант называется OTTO-2. Он стал отправной точкой для следующей серии. Во всех трёх её итерациях **способ обучения ранкера оставался прежним**, а агент развивал набор кандидатов и признаков.

Итерация	Что изменилось
Первая	Новый запуск агента с расширенными лимитами поиска. Добавлены источники кандидатов и признаки.
Вторая	Агент дополнил предыдущий набор новыми источниками кандидатов и признаками.
Третья	Агент добавил только признаки. Кандидаты остались прежними.



Оценка private выросла на каждом шаге. Ось показана не от нуля; больше — лучше.

Результат. Три итерации дали суммарно около **2.7%** к private относительно OTTO-2. Каждый шаг улучшал и локальную оценку, и private. Поэтому ценность этой серии — не только первоначальный выигрыш над простой базой: агент последовательно улучшал уже построенное им решение.

Первые два шага меняли одновременно кандидатов и признаки, поэтому их вклады не разделены. На последнем шаге кандидаты сохранились, а рост сопровождал добавление новых признаков. В числе предложенных идей были переходы с учётом типа события, похожие исторические сессии и длительность просмотра. Польза каждого отдельного признака не измерялась.

Новые итерации запускал человек. Агент работал в заданной архитектуре и лимитах; он не выбирал самостоятельно всю исследовательскую программу. Повторяемость такой серии при новых запусках агента пока не проверена.

4. Границы результатов и выводы

REES46: дополнительный сигнал на новом тесте. Совместный набор агента и DFS улучшил фиксированную базу. Вывод ограничен одним магазином и новым тестовым периодом. Устойчивость результата на других наборах данных не установлена.

- **Выбор по валидации.** Подтверждающая часть не была полностью изолирована: её оценки были видны в ранних прогонах. Правила принятия настроек базы и предложений агента различались; выбранное предложение вошло в тест 2019 даже после неподтверждения. Последнее уточнение плана 2020 внесено после просмотра валидации, без изменения вариантов и порогов теста.
- **Настройка базы.** Гиперпараметры меняли по одному; сочетания и равные вычислительные бюджеты не проверяли. Практический порог 0.001 основан на наблюдаемом разбросе случайных запусков, а не является универсальной границей полезности.
- **Доступность истории.** Проверка сравнивала признаки по полному журналу и по истории, обрезанной в момент прогноза. Найденную ошибку доступности категории исправили до обучения, обход песочницы — до запуска агента. Эти проверки уменьшают риск утечек, но не доказывают отсутствие всех возможных ошибок.

OTTO: развитие решения в ходе поиска. Последовательный рост private показывает работоспособность этого процесса. Его доказательная сила отличается от одноразовой итоговой проверки.

- **Повторное использование оценок.** Локальную выборку использовали для выбора многократно. На Kaggle отправили девять посылок; после достижения намеченной private-оценки продолжили ещё две итерации. Поиск адаптировался к этим оценкам. Критерий пригодности простой базы также изменили после просмотра локальных оценок.
- **Другая доступная информация.** В OTTO признаки используют более поздние события других сессий той же недели. Kaggle предоставляет эти данные, но при онлайн-прогнозе их ещё нет. Этот эксперимент не проверяет требование строгого использования только прошлой истории.
- **Контроль и новизна.** Превосходство над сильной ручной системой при одинаковых кандидатах не проверено. LLM могла воспроизводить известные решения соревнования; новизну предложений мы не установили.

Затраты. Цикл агента на REES46 занял около пяти часов, из них лишь около 6% — работа LLM. Основное время ушло на переобучение моделей для проверки идей. Для расширения поиска прежде всего нужно удешевлять эту проверку.

Код и воспроизведение. Репозиторий проекта; инструкции для REES46 и OTTO; числа теста 2020 и оценки посылок OTTO. Подготовка данных и точные разбиения описаны в инструкциях. Сырые данные, тяжёлые артефакты и расширенная проверка разброса случайных запусков находятся вне Git.

Участие ИИ. Автор выбирал направления и разрешал запуски; Claude Code проектировал значительную часть системы и написал код. Генерация SQL — отдельный исследуемый компонент. Ревью другими экземплярами LLM не исключает общих ошибок модели.