Автоматическая генерация признаков против ручного бустинга: LLM-агент и DFS на REES46

Отбор T-Lab 2026, RecSys, задача 1.

Ответ. Мы рекомендуем в интернет-магазине REES46 товары, новые для пользователя. Ручную базу (CatBoost на 80 признаках, настроенный по одному гиперпараметру за раз) мы сравнили с двумя способами строить признаки автоматически: LLM-агентом, который пишет SQL, и сеткой оконных агрегатов DFS. Базу обыграл только один вариант: все автоматические признаки агента и DFS поверх ручных, без отбора. На свежем тесте 2020 он дал +2.0% NDCG@20 к базе (+0.0030), доверительный интервал (CI) выше нуля на обоих сидах [по протоколу]. Этот вариант мы придумали после теста 2019, записали правило до теста 2020 и проверили один раз. Прирост лучшего признака агента ниже порога шума ≈0.001, у лучших колонок DFS прироста нет, а замена ручных признаков автоматическими при настройках базы дала −0.77% на тесте 2020 [по протоколу]. На других наборах колонки агента подняли базу на отложенных неделях Tinkoff и СберМаркета [holdout с отклонением], но на Kaggle у Tinkoff оказались ниже базы, а у H&M не различены [описательно].

- [**по протоколу**]: тест открыт один раз, варианты, пороги и правила решения записаны в Git до него, 95% CI парного бутстрапа по запросам. Числа валидации до теста 2019 входят в ту же проверку и метки не имеют.
- [**holdout с отклонением**]: правило решения записано заранее, но отложенные данные (holdout) открыты не так, как было записано.
- [**описательно**]: без проверки по протоколу, в том числе всё посчитанное после теста.
- [**исследовательский**]: OTTO-2 и OTTO-3, разведка на соревновании Kaggle OTTO. Неделю для выбора и неделю Kaggle там открывали много раз.

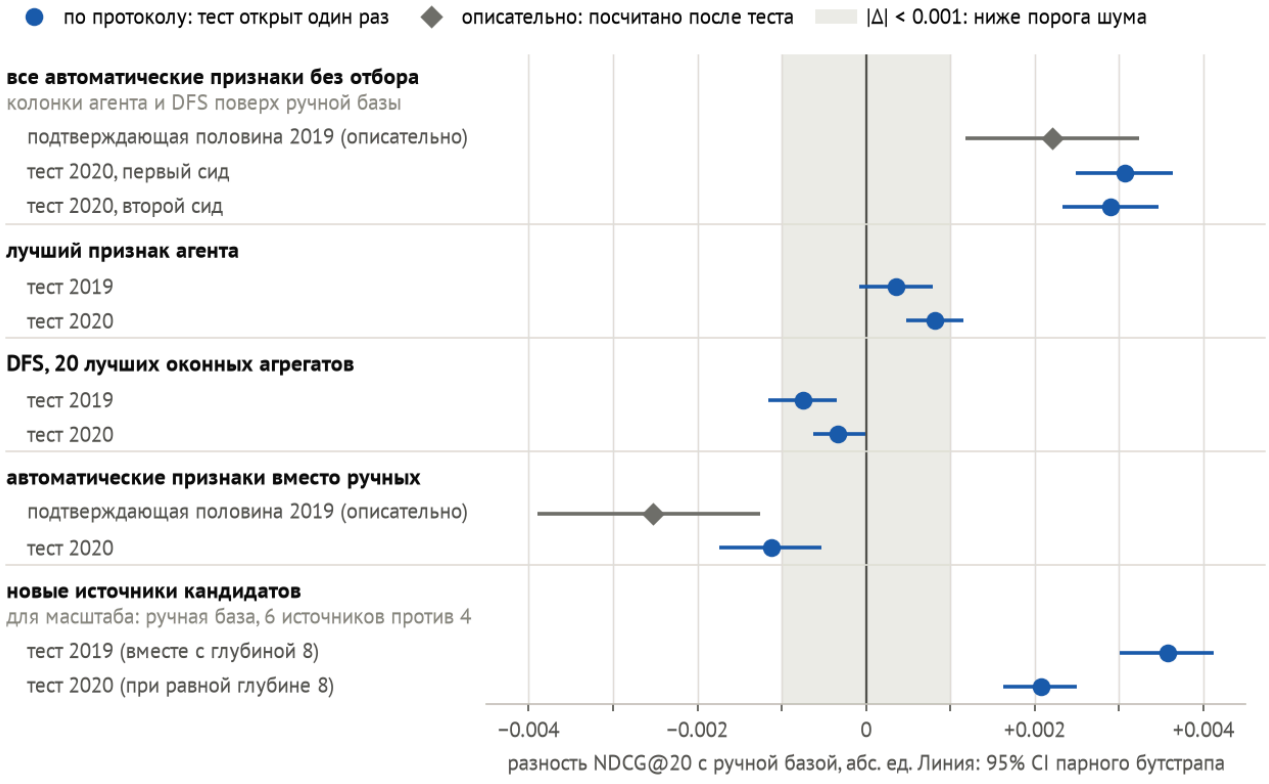


Рис. 1. Порог шума на тесте 2020 прошёл только набор всех автоматических признаков без отбора, а замена ручных признаков осталась ниже базы. Ромбы посчитаны после теста [описательно].

Табл. 1. Пункты условия (пересказ) и что по ним сделано.

Пункт условия	Что сделано
Воспроизводимый бустинг с хорошими ручными признаками	CatBoost на 80 ручных признаках, настроен по одному гиперпараметру за раз, сочетания не проверялись
Автоматизация генерации признаков либо альтернативный метод, превосходящий хорошо настроенный бустинг	LLM-агент и DFS. Поверх ручных признаков базу превзошёл набор всех автоматических признаков без отбора на тесте 2020 [по протоколу]. Отобранные признаки и замена ручных не превзошли [по протоколу]
Экспериментальная проверка, отчёт с результатами и ограничениями	Решения на одной половине валидации, проверка на другой, каждый тест открыт один раз
Данные для признаков до момента прогноза, без временных утечек	Признаки только из событий до момента рекомендации, построчный тест на утечки. Две найденные проблемы закрыты до использования

1. Задача и данные

Условие не предписывает ни набор, ни цель, ни горизонт, их мы выбрали сами.

- **Запрос и цель.** Набор REES46 содержит события интернет-магазина за октябрь–ноябрь 2019 и, для повтора во времени, за январь–февраль 2020. Момент рекомендации t наступает в начале дня, модель ранжирует товары, которых пользователь до t не касался. Цель: первая корзина или покупка такого товара за 24 ч. Покупки входят в цель, потому что журнал корзин неполон: у 56.0% первых покупок товара в октябре 2019 корзины перед ними нет. Метрику мы считаем по запросам: пользователям, активным за 48 ч до t и имеющим цель.
- **Метрика и разбиение.** NDCG@20 оценивает порядок первых 20 рекомендаций по всем целям запроса, включая не попавшие в кандидаты. В 2019 обучение идёт 15.10–07.11, валидация 08–13.11, тест 18–28.11 (72 709 запросов). Валидацию мы поделили по пользователям на половину для выбора и подтверждающую. Тест 2020: 14–29.02 (97 656 запросов) без 27–28.02, потому что журнал за 27.02 сломан.
- **Почему новые товары.** При цели «все покупки» правило без модели «сначала недавние товары пользователя» нашло 50 из 58 повторных покупок, а их пользователь сделал бы и без ленты. Цена выбора: прямые признаки «пользователь × товар», которые условие относит к пространству признаков, для кандидатов пусты.

2. Метод

База. Шесть источников кандидатов и 80 признаков в восьми группах. Источники: популярное, популярное в категориях и брендах пользователя, два вида соседей его недавних товаров по совместным просмотрам, переходы от просмотра к покупке. Модель: CatBoost с Logloss, глубина 8, 500 деревьев, два сида. NDCG@20 базы: 0.1442 на тесте 2019 и 0.1462 на тесте 2020 [по протоколу]. «Ручные» значит «спроектированные заранее по спецификации», а не найденные агентом или DFS. В базу вошли и идеи первого запуска агента, поэтому вклад автоматических признаков с нуля мы не измерили.

LLM-агент. За шесть раундов LLM пишет предложения: идею и SQL-запрос к DuckDB, дающий одну или несколько колонок. Песочница считает каждое предложение только по событиям до t, и база переобучается с ним. Предложение принимается, если на половине для выбора прирост больше 0.0005 и CI выше нуля на обоих сидах. Этот порог мягче порога шума и только пропускает предложение на подтверждающую половину. В промпте нет строк данных и ответов, со второго раунда в нём есть эффекты прошлых предложений, а `claude -p` работает без инструментов. Из 30 предложений с 66 колонками принято одно, его мы называем лучшим признаком агента.

DFS (Deep Feature Synthesis). Это контроль без LLM: 128 оконных агрегатов по товару, категории, бренду и пользователю. В модель идут 20 лучших по важности на обучении из 96 колонок, допущенных к отбору.

Варианты. С базой мы сравнивали четыре варианта: базу с лучшим признаком агента, базу с 20 лучшими колонками DFS, все автоматические признаки поверх базы без отбора и автоматические признаки вместо ручных. Вариант со всеми автоматическими признаками: база, 66 колонок агента и 128 DFS, всего 274 признака. Вариант с автоматическими признаками вместо ручных: ранги товара в шести источниках кандидатов и все автоматические колонки, 200 признаков.

Связь с работами. Как в CAAFE (arXiv 2305.03403), LLM пишет код признаков, у нас это SQL по событиям до t. Завышение лучшего признака на половине для выбора мы по аналогии связываем с переобучением оценщика на валидации из LATTEArena (arXiv 2606.09004, v3, §5.3).

3. Протокол

Решения мы принимали на одной половине валидации, проверяли на другой и каждый тест открывали один раз. Две модели мы сравниваем по разности NDCG@20 на одних запросах, с CI парного бутстрапа. CI не учитывает разброс между сидами, поэтому каждый вариант обучен на двух сидах.

- **Порог шума ≈0.001.** Разность меньше порога мы не считаем установленной даже при CI выше нуля. Модели, отличающиеся только сидом, расходятся на подтверждающей половине до 0.0013, у 2 из 10 пар CI не накрывает ноль. Пары пересчитаны вне Git [описательно].
- **Тесты.** Варианты, пороги и правила решения записаны в Git до чисел теста. Вариант со всеми автоматическими признаками мы придумали после теста 2019, в котором его не было. На подтверждающей половине 2019 он дал +0.0022 [описательно]. Правило для 2020 мы записали до теста: прирост от +0.0015 на каждом сиде при CI выше нуля. Гиперпараметры, колонки DFS и признак агента для 2020 взяты из 2019 без перевыбора.

Отступления от протокола.

- Первые 11 прогонов показывали и метрики подтверждающей половины, по нашей оценке в пользу базы.
- Глубину 8 база получила при CI выше нуля только на одном сиде, хотя агенту требовалось два, по нашей оценке тоже в пользу базы.
- Лучший признак агента вошёл в тест 2019, хотя на подтверждающей половине его прирост уже не подтвердился. Такой состав теста мы выбрали вручную, в чью пользу это, неизвестно.
- Последнее дополнение к плану теста 2020 мы внесли, когда уже видели метрики на валидации. Варианты и пороги оно не меняло, в чью пользу это, неизвестно.
- В разборе подтверждающей половины 2019 правило для варианта со всеми автоматическими признаками мы ужесточили после запуска прогонов, но до обучения его моделей: порог стал действовать на каждом сиде. Тогда мы видели только половину для выбора у одного прогона базы, и правка играет в пользу базы.
- Перенос на другие наборы: отложенные недели Tinkoff и СберМаркета мы открыли, а первые посылки Tinkoff отправили по одному общему решению, а не решали отдельно по каждому шагу.

Сколько раз открывали данные. Тест 2020 и отложенные недели Tinkoff и СберМаркета после вердиктов повторно использовал совет агентов: дополнительная проверка, где несколько LLM предлагают и отбирают признаки поверх всех автоматических. На половине для выбора базу мы оценили 27 раз, агента 38 раз (прошлые эффекты были в его промпте), DFS 2 раза. Подтверждающую половину 2019 и валидацию 2020 мы использовали и в разборах после теста 2019, поэтому их числа после него описательные.

4. Защита от утечек

Признаки читают только события до t. Будущее окно определяет только цели и то, какие запросы оцениваются, в признаки оно не попадает. Проверка утечек на днях 22.10 и 11.11.2019 и 22.01.2020 строит признаки дня по полному журналу и по журналу, обрезанному по t, и сравнивает все колонки построчно. SQL агента выполняется в песочнице DuckDB, где есть только события до t.

В OTTO признаки видят более поздние события других сессий той же недели. Kaggle их выдаёт, а в онлайн-системе их нет.

SQL агента проверяла отдельная LLM без права правки. На Tinkoff она до открытия отложенной недели посчитала корреляцию по событиям окна цели этой недели, но набор агента был заморожен раньше. Остальные находки собраны в Табл. 2. Мы не утверждаем, что утечек нет: проверено только перечисленное.

Табл. 2. Две найденные проблемы закрыты до использования, расхождение в OTTO дали округления.

Что нашли	Чем поймали	Как закрыли
REES46, 2020: код категории брался за весь период, а у 19 категорий он появляется только 01–05.02	тест на утечки	код берётся из событий до t, таблицы 2020 пересобраны до обучения моделей
обход песочницы через функцию DuckDB `json_execute_serialized_sql`	ревью кода	закрыт до первого раунда агента
OTTO: 4 колонки агента разошлись между полным журналом и журналом без продолжений сессий	тест на утечки	порядок округлений при параллельном суммировании, в один поток проверка прошла
скрытое использование ответов в SQL агента	проверка SQL отдельной LLM	не найдено в OTTO и при переносе. На REES46 вместо такой проверки работает песочница

5. Результаты на REES46

Поверх ручной базы помог только набор всех автоматических признаков без отбора.

- **Все автоматические признаки без отбора.** На тесте 2020 они дали +0.0031 и +0.0029 по сидам, правило требовало +0.0015 на каждом [по протоколу]. К базе это +2.0%. На всех 16 днях, включая 27 и 28.02, вердикты те же.
- **DFS, 20 лучших колонок.** DFS прироста не дал: −0.0008 и −0.0003 на тестах, обе разности меньше порога. CI ниже нуля оба раза, во втором вплотную к нулю [по протоколу].
- **Проверка перемешиванием.** После обоих тестов мы перемешали те же 194 колонки по строкам внутри дня: число и распределения колонок прежние, связь с парой пользователь–товар разрушена. На валидации настоящие колонки лучше перемешанных на 0.0025–0.0043 [описательно]. Перемешанные меняют базу на −0.0008…−0.0003 [описательно]. Значит, прирост несёт содержание колонок. По разложению на тех же данных его несут в основном колонки агента, одни DFS базу не поднимают [описательно]. На 2019 эта оценка вклада агента смещена: его предложения подбирались по половине для выбора 2019. На тесте состав прироста не разделён.
- **Кандидаты.** В кандидаты не попадает около половины целей и больше: ≈48% на валидации 2019 [описательно] и ≈58% на последних пяти днях обучения 2020 (29.01–02.02) [описательно]. Новые источники кандидатов дали на тесте 2019 наибольший прирост, +0.0036 вместе с глубиной 8, а на тесте 2020 при равной глубине повторились, +0.0021 [по протоколу]. Источники входят в ручную базу, агент на REES46 пишет только признаки.

Лучший признак агента и завышение при отборе. Даже если ни одно предложение не работает, лучшее из 30 на половине для выбора в среднем показывает около +0.0008 [описательно]. Лучший признак агента дал там +0.0013 и +0.0017 по сидам. На подтверждающей половине осталось +0.0004, и CI накрыл ноль. На тестах вышло +0.0004 и +0.0008 [по протоколу]: в 2019 CI накрыл ноль, в 2020 CI выше нуля, но прирост ниже порога и не установлен. Завышение поймала подтверждающая половина, порог приёма его пропустил. Прямого теста «пошагово против всего сразу» у нас нет: оба числа сравнивают с базой, а все автоматические признаки включают и DFS. В разборе после теста мы принимали предложения агента группами по пять, и на половине для выбора прошла одна группа. На подтверждающей половине её отставание от всех предложений агента сразу ниже порога шума [описательно]. Синергия это или сумма мелких эффектов, мы не различили.

Замена ручных признаков. Если оставить из ручных только ранги источников, база теряет 0.0167 на тесте 2020 [по протоколу] и 0.0171 на подтверждающей половине 2019 [описательно]. Автоматические признаки вместо ручных возвращают 93% этого вклада на тесте 2020 [по протоколу] и 85% на подтверждающей половине 2019 [описательно]. Но до базы они не дотягивают: −1.68% к базе на подтверждающей половине 2019 [описательно] и −0.77% на тесте 2020 [по протоколу], CI ниже нуля оба раза. Одни колонки агента возвращают 78% вклада, одни DFS 25%, оба числа на подтверждающей половине 2019 [описательно]. Оценка для агента смещена по той же причине, что в проверке перемешиванием. На тесте 2020 разность −0.0011 лишь чуть больше порога [по протоколу]. Вариант на 200 признаках мы не перенастраивали, поэтому вывод относится к настройкам базы.

Насколько настроен бустинг. До теста мы настраивали базу по одному гиперпараметру за раз на половине для выбора и сочетаний не проверяли. Глубину 8 мы приняли, 1000 деревьев и трудные

негативы отвергли. После теста выигрыша не дали глубина 10 и YetiRank у базы, пять значений трёх гиперпараметров у набора всех автоматических признаков и ранняя остановка у обоих вариантов [описательно]. Что база вышла на плато, это не доказывает. Бюджеты мы не выравнивали: ручная настройка заняла 16 подгонок, ≈2.1 ч, а агент ≈4.8 ч. Недонастройка базы облегчает выигрыш автоматическим признакам, но вариант с автоматическими признаками вместо ручных, проверку перемешиванием, перенос и совет агентов мы тоже не настраивали.

6. Границы вывода

Перенос на H&M, Tinkoff и СберМаркет

Мы переносили только агентскую часть: новый запуск агента на наборе и все его валидные колонки поверх ручной базы набора, без DFS и без перенастройки бустинга.

Табл. 3. На Kaggle рост от колонок агента у Tinkoff не повторился, у H&M не различён, у СберМаркета не проверялся. Колонки агента поверх базы набора, в процентах к базе.

Набор	Отложенные данные	Kaggle private
Tinkoff, NDCG@20	+6.2% и +3.6% по сидам [holdout с отклонением]	ниже базы, ≈−7.6% [описательно]
СберМаркет, MAP@50	+2.6% на обоих сидах [holdout с отклонением]	не проверен: на Kaggle колонки чаще пусты, чем на обучении, и не отправлялись
H&M, MAP@12	отложенной недели нет, неделя валидации +8.9% [описательно]	не различено [описательно]

Технические отклонения переноса мы записали в Git позже, чем применили, на значения это не влияет. Базы собирались с помощью LLM, которая знает эти соревнования, поэтому знание публичных решений не исключено. Промпт агента соревнование не называет, но схема данных узнаваема. На отложенных неделях запросом считается пользователь с целью в окне, а Kaggle оценивает другую популяцию.

У Tinkoff прирост есть только на отложенной неделе: на валидации CI накрывает ноль, на Kaggle колонки ниже базы на обоих сидах, причины мы не проверяли. У H&M нет свежей отложенной недели: неделя валидации была отложенной в прежнем эксперименте. MAP@12 на ней считается только по 1 905 покупателям, CI второго сида накрывает ноль, а на Kaggle больше половины клиентов получают одинаковый популярный ответ. Промпт агента на H&M набор не скрывает, и LLM знает решения этого соревнования. Если эффекта нет, наше правило сравнения посылок на Kaggle ошибается примерно в 11% случаев в каждую сторону, а прирост такой величины, как на REES46, при двух сидах не различает. Мест на лидербордах мы не заявляем ни здесь, ни в OTTO: все посылки поздние.

Совет агентов

В совете агентов LLM-генераторы и критики предлагают семейства признаков поверх всех автоматических, отбор вычёркивает вредные, и результат сравнивается с моделью на том же числе признаков без отбора. Ожидаемый исход «не различено» мы записали заранее, до кода, и он вышел на уже открытых данных: тесте REES46 2020 и отложенных неделях Tinkoff и СберМаркета [описательно]. Отбор совета не включился ни на одном наборе, поэтому мы проверили только генерацию. Эффекты меньше разрешения теста не исключены.

OTTO, где агент строит и кандидатов

На соревновании Kaggle OTTO по началу сессии нужно предсказать до 20 товаров для кликов, корзин и заказов, а Score взвешивает их Recall@20. На вопрос о настроенном бустинге OTTO не отвечает, потому что база там намеренно простая: история сессии, популярность и ранкер без настройки. Агент пишет SQL таблиц «товар × товар», источников кандидатов и признаков в лимитах на раунды, источники и кандидатов на сессию. Двухэтапную схему, лимиты, ранкер и правила выбора и остановки агент не выбирал, а новые итерации мы запускали вручную. Потолок кандидатов: Score по всем кандидатам сессии, верхняя граница для ранкера.

На шагах OTTO-2 и OTTO-3 посылку мы выбирали правилом, записанным заранее, но у OTTO-2 смена порядка двух посылок попала в Git только вместе с результатом первой. На неделе для выбора приросты шагов OTTO-3 больше разброса от выборки сессий [исследовательский]. Их 95% CI выше

нуля, но без учёта отбора по неделе для выбора, сида модели и запуска агента. У последнего шага CI по заказам задевает ноль. На том же ранкере новые наборы агента в расширенных лимитах дали больше, чем переобучение ранкера. Этот прирост шёл вместе с ростом потолка кандидатов, вклад не разделён. Лучший private 0.5963 дала итерация 3 [исследовательский], итераций после неё не было.

Табл. 4. Каждый шаг OTTO поднял Score на неделе для выбора и на private. Уровни недели для выбора и private несравнимы, сравнимы приросты. Private простой базы и OTTO-1 усреднён по двум сидам. Простая база и OTTO-1 [описательно], OTTO-2 и OTTO-3 [исследовательский].

Шаг	Неделя для выбора	Потолок кандидатов	Private
простая база	0.4778	0.4824	0.4906
OTTO-1: кандидаты и признаки агента	0.5633	0.6039	0.5788
OTTO-2: переобучен только ранкер	0.5653	0.6039	0.5805
OTTO-3, итерация 1: новый прогон агента, шире лимиты	0.5777	0.6514	0.5930
OTTO-3, итерация 2: итерация 1 и 18 новых предложений агента	0.5802	0.6639	0.5955
OTTO-3, итерация 3: итерация 2 и 20 новых предложений, только признаки	0.5810	0.6639	0.5963

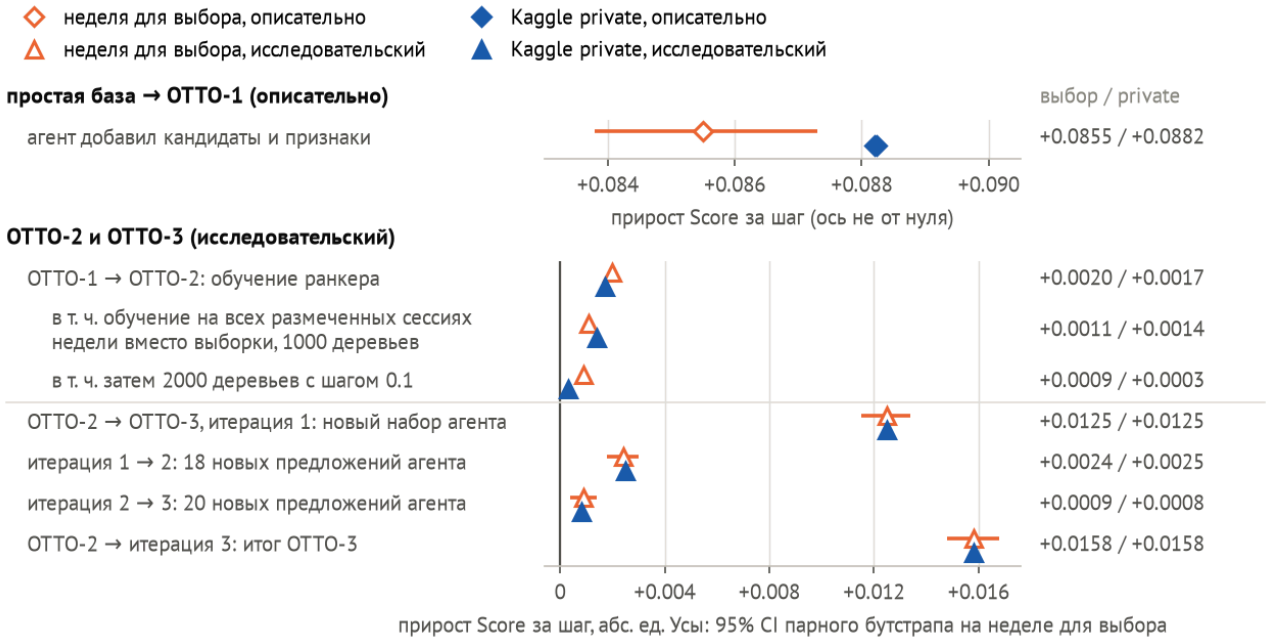


Рис. 2. Приросты за шаг на неделе для выбора и на private совпали по знаку на каждом шаге, а по величине разошлись не больше чем на 0.0006, кроме первого шага. CI без учёта отбора на неделе для выбора.

У шагов OTTO три ограничения.

- Это не проверка по протоколу. По заранее записанному плану простая база должна была быть не хуже правила без модели по каждому типу действий, а по кликам она уступила 0.0016 [описательно]. Сравнение мы перенесли на общий Score после чисел недели для выбора, поэтому числа отложенной недели и недели Kaggle подтверждением по протоколу не служат. На неделю Kaggle ушло 9 посылок. Правило «стоп при private ≥ 0.590», записанное до результатов, сработало на итерации 1, но мы отправили ещё две итерации, до заранее записанного предела.
- Придумано это или вспомнено, не различается. Проверяющая LLM по памяти сочла общеизвестными большинство предложений в каждом прогоне агента. Один признак итерации 2, по её памяти, повторяет веса типов действий из публичного решения. Пересказ части одного из публичных решений попал в журнал исследования раньше, чем план OTTO. Промпт соревнование не называет, с решениями мы не сверяли. Конвейер тоже строился с помощью LLM, которая знает OTTO.
- Это не один эксперимент. Простую базу с ранкером OTTO-2 мы не обучали, шаг к итерации 1 смешивает новые лимиты и новый запуск агента, а на каждый набор приходится один прогон агента и одна модель. Неделя для выбора смещена: агент видел recall на пробе той же недели, по ней мы выбирали варианты и итерации, и её события есть в истории финальных моделей.

Несмещённую оценку даёт только private. Признаки OTTO видят более поздние события других сессий той же недели, в онлайн-системе таких данных нет.

Выводы по наборам

Табл. 5. Рост от набора всех автоматических признаков по протоколу проверен только на REES46, а на Kaggle он не подтвердился там, где его проверяли. Остальные выводы о REES46 на других наборах не проверялись. Прочерк: не проверялось.

Вывод	REES46, тест 2020	H&M	Tinkoff	СберМаркет
все автоматические признаки поверх базы[1]	рост [по протоколу]	рост [описательно]	рост [holdout с отклонением]	рост [holdout с отклонением]
то же на Kaggle	—	не различено [описательно]	ниже базы [описательно]	не проверен
совет против равного числа признаков без отбора	не различено [описательно]	—	не различено [описательно]	не различено [описательно]

[1] На REES46 колонки агента и DFS, на других наборах только колонки нового запуска агента.

7. Сколько стоит агент

Генерировать признаки дёшево, отбирать дорого и трудно. Агент работал на REES46 ≈4.8 ч. LLM заняла 5.8% этого времени и стоила $2.89 по оценке `claude -p`. Больше всего ушло на переобучение базы: в среднем 406 с на предложение против ≈34 с у LLM. Сотням предложений нужны дешёвая оценка, подтверждающая половина в цикле и поправка на множественные проверки.

8. Ограничения

- Один магазин: по протоколу проверен только REES46.
- Главный результат: один тест 2020 и два сида, повтора во времени нет.
- Бустинг настроен по одному гиперпараметру за раз, бюджеты не выравнивались.
- Разброс между сидами для порога шума пересчитан вне Git.
- Оба тестовых периода REES46 уже открыты, свежего теста не осталось.
- Ревью кода и проверку SQL вели отдельные LLM: ошибки счёта они ловят, общие слепые зоны модели нет.

Приложения

- Журнал исследования: все варианты, абляции, затраты, глоссарий. OTTO-3: итерации агента, правила посылок и остановки.
- Сводка чисел: каждое число этого текста с меткой и источником.
- Воспроизведение задачи 1 и OTTO: от сырых файлов до чисел тестов и посылок.

Репозиторий: github.com/suprend/tlab-recsys-2026-task1, ссылки ведут на коммит сдачи в `main`.